

캐치플라워 (CatchFlower) — AI 활용 기술 문서

AI를 두 층에서 썼다. 만드는 데 쓴 AI와 제품 안에서 도는 AI다. 이 문서는 그 둘을 갈라서, 어떤 도구에 무엇을 시켰고 결과를 어떻게 검증했는지를 적는다.

개발 도구	Claude Code (Anthropic Claude Opus) — 터미널 2개 병행
제품 내 AI ①	PlantNet API k-eastern-asia (4,932종) — 종 판별
제품 내 AI ②	ML Kit Image Labeling (온디바이스 · 번들 모델) — 꽃 여부 1차 필터
검토했다 안 쓴 것	Gemini 2.5 Flash-Lite · Kindwise Plant.id · GPT-4 계열 (5절에 이유)
AI가 안 만든 것	꽃 일러스트 200장 (Figma · 사람 작업) · UI 문구 전체
개발 기간	2026-08-04 ~ 08-10 (7일) · 진행 기록 47회차 · 커밋 42개
산출 규모	Android main 14,789줄 + 테스트 10,084줄 · iOS 7,416줄 · 문서 10,162줄

1. 개발에 쓴 AI — Claude Code

1-1. 어떻게 돌렸나 — 터미널 2개를 계약서로 묶었다

iOS와 Android를 동시에 만들었다. AI 세션 두 개가 같은 서버·같은 DB를 건드리므로 한쪽이 필드명을 바꾸면 다른 쪽이 조용히 깨진다. 그래서 순서를 뒤집었다.

```
프로젝트 맥락/공유계약_iOS_AOS.md  ← 두 세션이 혼자 바꿀 수 없는 것
├ DB 컬럼명 · enum 문자열
├ 정책 숫자 (임계값 · 반경 100m · 하루 1회 · 최소 인원 10명)
└ Mock 인식기의 동작 규칙
  ↓ 이 문서를 고치고 진행.md에 남긴 뒤에만 코드를 고친다
터미널 A [iOS · SwiftUI]           터미널 B [Android · Compose]
```

파일	역할	왜 필요했나
공유계약_iOS_A0S.md	플랫폼이 혼자 못 바꾸는 것	한쪽이 ai_confidence 를 Double로 넓혀 다른 쪽 파싱이 깨진 일이 실제로 있었다 (진행.md (24))
세션시작_iOS.md / 세션시작_A0S.md	새 세션이 가장 먼저 읽는 문서	컨텍스트가 끊겨도 환경·금지사항이 유지된다
구현현황_iOS.md / 구현현황_A0S.md	지금 무엇이 되고 무엇이 안 되나	"다 됐다"는 보고가 축적되는 것을 막는다
진행.md (4,511줄)	회차별 기록	무엇을 했는지가 아니라 무엇이 틀렸는지를 남긴다

인계 문서가 가장 위험했다. 세션시작_A0S.md 가 나흘 낚아 "코드 6,870줄 · PlantNetRecognizer 가 0줄"이라고 말하고 있었다. 실제로는 14,789줄이고 실기기 실호출까지 됐다. 한때 맞았던 글은 거짓이 된 뒤에 결함을 가리는 쪽으로 작동한다 — 그래서 47회차를 이 문서 갱신에 썼다.

1-2. 실제로 쓴 프롬프트 — 설계를 바꾼 것만 뽑았다

전부 옮기면 47회차 분량이라, 결과물이 실제로 달라진 프롬프트만 적는다. 공통점은 짧고, 답을 지정하지 않고, 근거를 되묻는다는 것이다.

#	실제 프롬프트	AI가 하려던 것	바뀐 결과
1	1,000유로면 얼마나... 제미나이 api로 풀어보는 방법은 없나?	전용 꽃 인식 API만 비교	범용 멀티모달 단가를 대보니 자릿수가 달랐다 . 연 226만원 → 20만원 안이 나왔고 최종 설계가 바뀌었다
2	하루 500건 무료인데 연 20만 건이 1,000유로라는 거야?	"무료 500건/일" 표기를 물량으로 읽음	약관을 다시 읽으니 물량이 아니라 라이선스 최소 계약 (€1,000) 이었다. 비용 문서를 정정했다
3	정확도는 각각 어느정도이지?	벤더 표기(≈80%)를 근거로 채택	조사 결론이 " 공개 자료로는 결정할 수 없다 "였고, 그래서 실측 200장 을 설계했다
4	지금 너 너무 사진인식안되는거에 꽃힌거는 아니냐? 일단 서비스 작동을 위해서 필요한거 먼저 진행해도된다	정확도 튜닝을 계속 파고들	맞는 지적이었다. DB가 0테이블 이라 로그인·저장·랭킹이 시작조차 못 하는 상태였다. 스키마로 방향을 틀었다
5	aos ios 개발 둘 다 할 것	"iOS 먼저" 권고	두 플랫폼 동시 개발로 뒤집혔고, 그 결과가 공유계약 문서 다
6	모든 아이콘을 적용시킬필요는 없다. 현재 디자인에 있는 아이콘들에 필요한 부분들을 적용시키는 거야	납품 아이콘 44종을 전부 넣으려 함	7종만 넣었다 . 안 쓰는 아이콘을 넣으면 그것을 놓을 자리를 만들게 되고, 그 자리는 눌러도 아무 일 없는 버튼 이 된다
7	화면상에 있는 사진을 찍어도 허용되게 잠시 열어둘수 있나?	(막힌 이유를 결함으로 오해할 수 있던 지점)	모니터 속 꽃은 모아레 때문에 ML Kit이 Pattern 으로 읽는다 — 필터가 맞았다 . QA용 파일 스위치를 따로 만들어 뒤쪽 흐름을 손으로 검증했다
8	전체 권한줄게 쪽쪽진행해 api키 필요한 경우그런경우만 답변 요청하고	매 단계 확인을 요청	막히는 지점을 "키가 필요한 경우"로 한정 했다. 그 외에는 판단하고 기록으로 남기는 방식으로 바꿨다

두 번 연속으로 "이게 얼마나"는 되물기가 설계를 바꿨다(#1·#2). AI가 만든 비교표는 정교했지만 후보 집합 자체가 좁았다. 가격표를 정밀하게 비교해도 후보가 빠져 있으면 정밀함이 무의미하다 — 이 프로젝트에서 AI 사용법의 핵심 교훈이다.

1-3. AI에게 준 상시 규칙 — 프롬프트보다 이게 더 많이 일했다

매번 말하는 대신 문서로 고정해 세션마다 읽히게 했다.

규칙	왜
UI 문구를 새로 쓰지 않는다	전부 디자이너_업무/A_문구·버튼_스펙.md 에 있다. 없으면 A 문서에 먼저 추가하고 기록한 뒤 쓴다
생성물을 직접 고치지 않는다	CSV·SVG·xlsx·SQL은 _tools/*.py 가 원본이다. 결과 파일을 고치면 다음 생성에서 날아간다
키를 소스에 넣지 않는다	local.properties → buildConfigField → AppSecrets. 검증은 이름과 길이로만 하고 값을 절대 출력하지 않는다
실측 보고 전에 유료 API를 부르지 않는다	PlantNet 누적 호출을 세어 기록한다 (현재 16건 / 500건·일)
원본 응답을 캐시한다	채점 규칙을 고쳐도 쿼터를 다시 쓰지 않는다. 실제로 floor 재채점을 4번 했다
계약값을 혼자 바꾸지 않는다	필드명·enum·정책 숫자는 공유계약을 고치고 기록한 뒤에만
회차마다 진행.md에 남긴다	컨텍스트가 끊겨도 결정의 근거가 남는다

1-4. AI가 만든 것을 어떻게 믿지 않았나

이 프로젝트에서 가장 많은 시간을 쓴 부분이다. AI는 "됐습니다"를 아주 잘 말한다.

컴파일 성공	→ 증거가 아니다 (진행.md (17))
테스트 초록	→ 증거가 아니다 (진행.md (22)(31)(32))
정책이 붙음	→ 규칙이 도는 것과 다르다 (진행.md (23))
빌드 성공	→ 검사 대상이 안 읽혔을 수 있다 (진행.md (41))

실제로 겪은 것	증상
테스트 249개가 전부 초록인 상태에서 앱이 죽고 화면에 null 이 떠 있었다	초록
랭킹이 정렬이 틀린 채로 예쁘게 렌더됐다	정상처럼 보임
answered > 0 이라는 느슨한 단정 때문에 점수 0.002 하나로 통과했다	초록
res/ ·문서를 읽는 검사 12개가 Gradle 입력에 없어서 안 돌면서 초록이었다	BUILD SUCCESSFUL
RLS 정책이 대시보드에 다 붙어 있는데 정책 안의 서브쿼리가 다시 RLS를 타서 구멍 3곳	초록

해법으로 쓴 것: 돌연변이 검증. 검사를 믿기 전에 코드를 일부러 틀리게 바꿔 그 검사가 실제로 빨개지는지 확인한다. 누적 182건을 이렇게 확인했다.

돌연변이	되돌린 것	결과
179	floor 0.30 → 0.05	expected:<77> but was:<42> 로 빨감
180	0.05를 0.30으로 되돌림	화면 12로 가는 비율을 기록한다 FAILED
181	preFilter 를 항상 통과하도록 교체	FAILED (QA 스위치가 켜진 채 배포되는 것을 막는다)
182	진단 로그에서 학명을 제거	응답 요약 로그가... FAILED → 복원 후 바이트 동일 확인

살아남은 돌연변이도 있었고 그게 더 값졌다. RGB_565 → ARGB_8888 을 되돌린 돌연변이는 값 테스트 4개를 전부 통과했다 — 픽셀도 계산도 안 틀리고 투명 배경만 검게 칠해진다. 검사가 볼 수 없는 층이 있다는 뜻이고, 그건 문서에 적었다.

1-5. 이 제출물도 스크립트다

이 PDF를 손으로 만들지 않았다. 제출물/_tools/build_pdf.py 가 마크다운을 변환한다 (Chrome headless 인쇄 — 이 맥에 pandoc이 없고 brew install --cask 가 막혀 있다). PDF를 손으로 고치면 원본과 어긋나기 때문이고, 그건 이 프로젝트의 생성물 규칙과 같다.

변환기에도 테스트를 붙였다(test_build_pdf.py). 이유는 조용히 틀리는 방식이 있어서다 — 표 칸 안의 ` | ` 가 칸을 쪼개고, 2 * 3 * 4 가 2 3 4`가 되고, 이미지 경로가 틀려도 Chrome은 PDF를 정상 생성하고 그 칸만 빈다 (오류도 안 난다). 셋 다 실제로 걸렸고, 마지막 것은 PDF를 열어 봐도 눈에 안 띈다.

2. 제품 안에서 도는 AI ① — PlantNet (종 판별)

2-1. 무엇을 어떻게 부르나

엔드포인트	https://my-api.plantnet.org/v2/identify/k-eastern-asia
모델 범위	4,932종 (동아시아 프로젝트)
요청	multipart/form-data · organs=flower · nb-results=10 · include-related-images=false
사진	긴 변 1,600px로 리사이즈해서 보낸다 (원본을 그대로 보내지 않는다)
응답	학명 + 점수 배열
요금	무료 등급 일 500건 · 현재 누적 실호출 16건

organs=flower 를 명시한다 — 우리가 받는 사진은 항상 꽃이라 기관을 알려주면 정확도가 오른다.

2-2. AI 답을 그대로 쓰지 않는다 — 세 겹을 통과해야 후보가 된다

사진

- ↳ ① ML Kit 온디바이스 필터 꽃이 아니면 여기서 끝 (유료 호출 안 함)
- ↳ ② 개화월 하드 필터 지금 피는 종만 후보 (8월 = 98종)
- ↳ ③ PlantNet 실호출
- ↳ ④ 학명 색인 도감 200종에 없는 학명은 버린다
- ↳ ⑤ 후보 3개 + floor 0.05
- ↳ 화면 09 (사용자가 고른다) / 화면 12 (실패)

② 개화월 하드 필터는 선택이 아니라 필수다. PlantNet은 4,932종 중에서 고르므로 11월에 "벚꽃"을 1순위로 준다. 그런데 화면에는 그냥 "AI가 좀 틀렸네"로 보인다.

⑤ 최종 결정은 AI가 아니라 사람이 한다. 점수가 높아도 이 꽃이에요 / 다른 꽃이에요 를 묻고, 애매하면 후보 3개를 나란히 놓는다. 유사종(민들레 vs 서양민들레)은 사람도 헷갈리므로 AI가 단정하지 않게 설계했다.

2-3. 실측 — 200장을 라벨로 재고, 원본 응답을 전부 캐시했다

TF-flowers 5클래스 × 40장. `ios/Tools/plantnet_measure.py` 가 앱과 같은 규칙을 재현한다(개화월 필터 + 학명 색인 + 후보 3개 + floor). 응답 200개를 캐시했으므로 채점 규칙을 고쳐도 쿼터를 다시 쓰지 않는다.

클래스	원시 Top-1	앱 Top-1
sunflowers	95.0%	95.0%
tulips	95.0%	95.0%
dandelion	72.5%	90.0%
roses	62.5%	62.5%
daisy	55.0%	42.5%
합계	76.0%	77.0%

⚠ 이 77%를 "합격선 통과"로 쓰지 않았다. 표본이 쉽다 — 도감의 AI 난이도 '상' 51종은 여기 없다. 실측 보고를 한 번 정정한 기록이 `진행.md` (21)에 있다. 지표가 쉬운 표본에서 나오면 합격이 아니라 상한이다.

2-4. 실측이 잡은 것 — 정답 0.606이 오답 0.003에게 지고 있었다

원시 76%인데 앱은 21%였다. 60%p 차이의 원인은 API가 아니라 우리 코드였다.

0.606 *Rosa chinensis* → 속 대표를 도감번호 최솟값으로 고정 → 찔레꽃(5~6월) → 8월 탈락
0.003 *Begonia grandis* → 베고니아 → 1순위로 채택

도감 200종 중 94종이 다종 속에 있고, 그중 30속은 개화월이 서로 다르다. 예외가 아니라 절반의 문제였다. 색인이 호출 시점의 후보 집합을 받아 속 안에서 제철 종을 고르게 고쳤다.

왜 앱을 커서는 못 봤나. 8월에 장미를 찍으면 베고니아 가 뜨는데 그게 그냥 오인식으로 보인다. 달을 바꿔 재야 드러난다 — 한 달로 고정된 측정은 원인을 귀속할 수 없다.

2-5. AI 점수를 신뢰도로 착각하지 않았다 — floor 0.30 → 0.05

PlantNet 점수는 4,932종에 퍼진 확률이라 정답도 0.1 근처에 흔히 온다 (정답 사진의 25% 분위가 0.157). 처음 실패 임계값을 0.30으로 뒀더니 버려진 4장이 전부 정답이었다(실기기 실측 — 장미 0.110 · 서양민들레 0.112 · 0.185 · 0.019).

floor	1순위 정답률
0.30 (처음)	50%
0.10	76%
0.05 (현재 · 오너 승인)	80%

낮춰도 오등률이 늘지 않는 이유는, 이 값이 "확정" 관문이 아니라 "후보로 보여줄 자격" 이기 때문이다. 점수가 낮으면 화면 09에서 사용자가 고른다. 0.05는 iOS·Android 공용 계약값이라 어느 한쪽이 혼자 바꿀 수 없다.

3. 제품 안에서 도는 AI ② — ML Kit 1차 필터 (온디바이스)

유료 호출을 줄이려고 무료·온디바이스 AI를 앞에 뒀다. 사진 1,000장으로 실측했다 (TF flowers 500 + Imagenette 500 · Pixel 8 에뮬레이터 API 36).

항목	실측
재현율 (꽃을 통과시킴)	100.0% — 막힌 정상 촬영 0장
차단율 (꽃아님을 막음)	92.4%
지연	중앙값 19~20ms (p90 22ms)
APK 증가	arm64 기준 약 14MB (so 11MB + 모델 3MB)
과금	0원 (번들 모델 · 네트워크 없음)

확정 설정: 라벨 Flower · Petal · Blossom / 임계값 0.20.

처음엔 Plant · Leaf · Garden 도 넣어 뒀다. "근접 촬영이면 Plant가 더 높게 나올 것"이라는 추측이었는데 측정은 정반대였다 — Plant 는 꽃아님 사진 489/500장에도 붙는다(배경 초목). 넣으면 차단율이 96.6% → 62.8%로 무너지면서 재현율은 오르지 않는다.

● 가장 위험했던 함정: 데이터셋 라벨 노이즈가 잘못된 설정을 유도한다. 처음 재현율이 96%로 나왔다. "놓친 꽃 20장"을 전부 열어봤더니 16장이 꽃이 아니었다 — 행진 악대, Roses 상점 간판, 매달린 찻잔, 금속 풍선, 벽돌 건물. ML Kit이 맞고 데이터셋이 틀렸다. 이걸 모르고 96%를 보면 임계값을 낮추게 되고, 그러면 차단율이 무너져 비용 절감 자체가 사라진다. 숫자만 보고는 절대 못 잡는다.

임계값을 0.30이 아니라 0.20으로 내린 근거 (DAU 1,000 환산):

임계값	허출	막힌 정상 촬영
0.20 (채택)	476건/월	0건
0.30	213건/월	201건

263건 아끼려고 손에 진짜 꽃을 들고 있는 201명에게 꽃이 아닐 수도 있어요 를 보여주는 거래다. 0.30 이상에서 막히는 사진을 전부 열어보니 역광 민들레 흙사·흑백 접사· Flower 0.28 로 간신히 못 넘긴 근접 촬영 — 우리 사용자가 실제로 찍은 사진들이었다.

측정 코드는 출력만 하지 않고 단정한다(재현율 $\geq 99\%$ · 차단율 $\geq 90\%$ · 지연 $\leq 200\text{ms}$). 출력만 하면 나중에 라벨셋을 건드려도 테스트가 계속 통과한다.

4. AI 실패를 화면이 가리지 않게 했다

어떤 꽃인지 알 수 없었어요 (화면 12)는 원인이 셋인데 화면에는 똑같이 보인다.

	원인	우리 책임인가
Ⓐ	PlantNet이 아무것도 못 알아봤다	아니다 (API 한계)
Ⓑ	알아봤지만 도감 200종·개화월에서 전부 걸렸다	우리 도감이 좁다 (B-4)
Ⓒ	통과했지만 1순위가 floor 미달이다	우리 정책이다 (B-3-a)

로그 네 줄로 갈라 두고, 그 로그의 내용까지 테스트로 고정했다 — 로그는 조용해져도 증상이 없기 때문이다.

```
1차필터: 꽃=true top=Flower(0.71)
판별 호출 직전: PlantNetRecognizer 후보=98개 (8월) ← 여기가 과금 시점
판별 응답: 원시 7종 → 학명 매칭 2종 → floor 통과 1종
화면 12: 원인=Ⓒ (1순위 0.031 < floor 0.05)
```

이 구분이 없어서 "API가 문제인 줄 알았는데 우리 임계값이었다"를 한 번 겪었다. 그리고 판별 호출 직전 줄이 있어야 어느 촬영이 과금됐는지 사후에 확인할 수 있다 — "몇 건 썼는지 모른다"는 상태를 만들지 않았다.

5. 검토하고 안 쓴 AI — 왜 버렸는지가 근거다

Gemini 2.5 Flash-Lite — 가장 싸지만 점수를 못 믿는다

단가는 압도적이었다(건당 0.68원 · DAU 1,000에서 연 20만원 vs PlantNet Pro 226만원). 그런데 버렸다.

	PlantNet (분류 모델)	Gemini (LLM)
점수의 의미	보정된 확률 — 0.72가 실제 72%	"95% 확신합니다"라고 말할 뿐
모를 때	낮은 점수를 준다	그렇듯하게 지어낸다

우리 판별 설계(난이도별 임계값 60/70/85 + floor)는 보정된 확률을 전제로 만들어졌다. 그리고 난이도 '상' 51종이 진짜 시험대다 — 민들레 vs 서양민들레처럼 사람도 헷갈리는 데서 LLM은 그럴듯한 답을 자신 있게 낸다. 오등록은 "이 앱 틀렸다"로 오히므로 정확도보다 위험하다.

덧붙여 Gemini 무료 등급은 데이터를 제품 개선에 사용한다. 사용자 사진 + 위치를 보내는 앱이라 무료 등급을 쓸 수 없다.

버리지 않고 남긴 자리: FlowerRecognizer 인터페이스 뒤의 대안 엔진, 그리고 꽃 이야기 200종 초안 생성(아직 미사용 — 쓰게 되면 식물 정보라서 출처 표기가 필수다).

Kindwise Plant.id — 연 135만~677만원. 무료 등급이 없다

GPT-4 계열 — 비교 자료가 우리 조건과 안 맞았다

찾은 유일한 비교(Kindwise 블로그 · 50장 · 2024-02 · GPT-4 Turbo 42%)는 ① 벤더가 자기 제품과 비교한 것이고 ② 60%가 실내 관엽식물(우리는 한국 야생화)이고 ③ 2024-02 모델이라 2세대 전이다. 42%는 현재 추정치 아니라 하한선이다.

"자료가 없다"를 확인한 것도 성과였다. 공개 자료로 결정할 수 없다는 결론이 실측 200장 설계를 낳았고, 그 실측이 우리 코드 버그(2-4절)를 잡았다.

6. AI가 만들지 않은 것

정직하게 갈라 둔다. AI 활용 문서에서 이 절이 빠지면 나머지 절도 못 믿는다.

항목	만든 방법
꽃 일러스트 200장	사람 작업 (Figma) — PNG 512×512 RGBA. 생성 AI 아님. 발주서는 <code>디자이너_업무/C_꽃일러스트_발주서.md</code>
앱·인앱 아이콘	사람 작업 (납품 44종 중 7종만 적용)
UI 문구 전체	사람이 확정한 <code>A_문구·버튼_스펙.md</code> 가 원본. 코드에서 문구를 창작하지 않는다 (금지어 목록이 아니라 승인된 문구만 허용으로 뒤집었다)
도감 200종 데이터	사람이 정한 목록 + <code>꽃도감/_tools/flowers.py</code> 가 생성·검증 (개화월 파싱은 한 곳에서만)
정책 숫자 35항목	오너 결정 (<code>오너_결정사항.md</code> 가 원본) — floor 0.05를 포함해 AI가 혼자 정한 값이 없다

7. AI 활용 요약 — 무엇이 실제로 효과가 있었나

한 일	효과
AI를 두 세션으로 나누고 계약서로 묶었다	iOS·Android를 7일에 동시 개발. 필드명 충돌은 계약 문서에서 잡혔다
회차마다 "무엇이 틀렸는지"를 기록	4,511줄 · 47회차. 컨텍스트가 끊겨도 결정의 근거가 남는다. 같은 함정을 두 번 밟은 경우까지 적혀 있다
되문기로 후보 집합을 넓혔다	"이게 얼마나" 두 번이 비용 설계를 두 번 뒤집었다 (226만원 → 0원)
초록불을 증거로 쓰지 않았다	돌연변이 182건. 초록 249개 상태에서 앱이 죽어 있던 경험이 이 습관을 만들었다
AI 답을 사람이 최종 결정	화면 09에서 사용자가 고른다. 오등록이 정확도보다 위험하다는 판단
AI 실패의 원인을 세 갈래로 로깅	"API가 문제인 줄 알았는데 우리 정책이었다"를 다시 겪지 않는다
원본 응답 캐시	floor를 4번 재채점하면서 유료 호출 0건 추가

가장 크게 배운 것 하나만 남긴다. AI는 요구한 것을 잘 만들고 "됐습니다"를 아주 잘 말한다. 그래서 이 프로젝트에서 가장 많은 시간을 쓴 일은 기능 추가가 아니라 "이 검사가 어떤 경우에 빨개지는가"를 먼저 답하는 것이었다. 컴파일 성공 · 테스트 초록 · 정책 불음 · 빌드 성공 — 네 가지 다 성공처럼 생긴 출력을 낸다.

8. 함께 보는 문서

문서	내용
제출물/게임_소개.md	게임 개요 · 플레이 방법 · 실행 방법
프로젝트 맥락/진행.md	개발 전 과정 47회차 — 이 문서의 모든 숫자의 출처
프로젝트 맥락/공유계약_iOS_AOS.md	두 AI 세션이 혼자 못 바꾸는 것
프로젝트 맥락/AI인식_API_비용검토.md	5절 비용·정확도 비교의 원본 (세 번 정정한 이력 포함)
프로젝트 맥락/오너_결정사항.md	사람이 정한 35항목
android/app/src/main/java/com/catchflower/app/recognizer/	판별 코드 — 필터 · 색인 · floor · 로그